




House MD

NLP Projesi: Medikal Diyaloglar

TEXT-CLINIC

Ahsen akır – Furkan Yılmaz

Genel Bakış

Projenin Amacı:

House MD dizisinden derlenen Türkçe hasta-doktor diyalogları üzerinde Doğal Dil İşleme teknikleri kullanarak tıbbi konuşmaların bağlamını, amacını ve içerdiği medikal varlıkları analiz etmektir.

Proje Kapsamı ve Görevler:

Cümlelerin konuşma amacını, taşıdığı duygu tonunu ve sarkazm içerip içermediğini tahmin etmek.

Diyalogdaki tanı aşamasını ve ilişkili organı/sistemi bulmak.

Metin içerisindeki Semptom, Test, İlaç ve Prosedür gibi medikal varlıkları tespit etmek.

Çıktılar:

Hem geleneksel hem de modern Derin Öğrenme tabanlı modeller.

Tüm modellerin canlı olarak test edilebildiği kullanıcı dostu bir web arayüzü.




Ön İşleme

Veri kalitesini ve modelin başarısını artırmak ön işleme uygulanmıştır.

Metin Temizliği: Özel karakterler ve anlamsız ifadeler temizlenmiştir.

Etiket Normalizasyonu: Türkçe karakter düzeltmeleri ve yazım farklılıkları birleştirilmiştir. (Örn: "endişeli" → "endişe", "tarafsız" → "nötr")

Dengesiz Sınıf Filtrelemesi: Modelin sağlıklı öğrenebilmesi için çok nadir görülen etiketler elenmiştir.



Özellik Seçimi

Modellere metni ve bağlamı en iyi şekilde aktarmak için çeşitli özellik çıkarım yöntemleri kullanılmıştır:


Metin Temsili (TF-IDF): Geleneksel modeller için diyalog metinleri, kelime frekanslarına ve doküman içi ağırlıklarına göre vektör uzayına aktarılmıştır.

Bağlam Ekleme (One-Hot Encoding): Cümleyi "House"un mu yoksa "Hasta"nın mı söylediği anlamı değiştirdiği için, konuşmacı kimlikleri kategorik bir özellik olarak modele entegre edilmiştir.

Numerik Medikal Özellikler: JSON ayrıştırması sonucunda elde edilen "Cümledeki Medikal Varlık Sayısı" (entity_count) modele matematiksel bir ağırlık olarak verilmiştir.

Boolean Tetikleyiciler: Cümlede Semptom, ilaç, Test veya Prosedür geçip geçmediğini belirten ikili (0-1) kolonlar oluşturulmuştur.

Feature selection process in NLP



Modelleme Yaklaşımı

Projede hem açıklanabilir geleneksel algoritmalar hem de yüksek kapasiteli yapay sinir ağları kullanılarak hibrit bir yaklaşım sergilenmiştir:

Geleneksel Makine Öğrenmesi Modeli

LogisticRegression: Veri setindeki etiket dengesizliğini için sınıf ağırlıklandırması uygulanmıştır.

Derin Öğrenme ve Transformer Modelleri

Metin Sınıflandırma (BERT): Türkçe dil yapısını çok iyi anlayan, projeye özgü görevler için Fine-Tuning yapılmıştır.

Medikal Varlık Tanıma (NER): Metin içindeki tıbbi terimleri token bazında tespit edebilen özel bir Token Classification mimarisi eğitilmiştir.



Model Performansı

Görev	Doğruluk (%)	F1-Skoru (%)	Model Türü
Sarkazm	85.3	88.5	Lojistik Regresyon
Organ / Sistem	35.5	39.4	Lojistik Regresyon
Tanı Aşaması	30.5	32.0	Lojistik Regresyon
Duygu (Emotion)	20.5	22.5	Lojistik Regresyon
Konuşma Amacı	18.1	16.7	Lojistik Regresyon
BERT Sınıflandırma	52.4	39.1	Derin Öğrenme
Medikal NER	88.7	31.0	Derin Öğrenme

Etik ve Riskler

Projenizin medikal bir bağlamı olduğu için sunumun sonunda mutlaka değinmeniz gereken bazı etik sınırlamalar bulunmaktadır.

Kurgusal Veri Yanılgısı: Veri seti gerçek bir hastaneden değil, kurgusal bir televizyon dizisinden alınmıştır. Dolayısıyla çıkarılan teşhis, hastalık ve semptom ilişkilerinin klinik bir geçerliliği yoktur.

Otomasyon Yanılgısı: Bu sistem tanı koyucu tıbbi bir yazılım değildir. Gerçek hayatta doktorların veya sağlık profesyonellerinin karar alma süreçlerinin yerini alamaz, sadece dilsel iletişim analizi yapar.

Öznellik ve Dengesizlik: Veri setinin etiketlenmesi kişisel yorumlara açıktır. Ayrıca Dr. House karakterinin doğası gereği, model sarkazm veya agresif duyguları tahmin etmeye istatistiksel olarak daha eğilimli olabilir.

Gerçek Veriyle Kullanım ve Gizlilik: Bu veri seti anonim veya kurgusaldır. Ancak bu mimarinin gerçek hasta verilerine uygulanması durumunda kişisel verilerin korunması kanunlarına uyumluluk ve verilerin anonimleştirilmesi zorunludur.