

House M.D. Türkçe Medikal Diyaloglarında NLP Tabanlı Diyalog Analizi

1. Özet

Bu projede, House M.D. dizisinden oluşturulan Türkçe medikal diyalog veri seti üzerinde doğal dil işleme yöntemleri kullanılarak konuşma amacı, duygu, sarkazm, tanı aşaması ve organ/sistem sınıflandırması yapılmıştır. Ek olarak, metinlerde geçen semptom, test, ilaç ve prosedür gibi medikal varlıklar çıkarılmış ve model özelliklerine dahil edilmiştir.

Sistem iki ana yaklaşım üzerine kurulmuştur: klasik makine öğrenmesi tarafında TF-IDF metin temsili, konuşmacı bilgisi ve medikal varlık özellikleriyle desteklenen Logistic Regression modeli; derin öğrenme tarafında ise Türkçe BERT tabanlı sınıflandırma ve BIO etiketleme yaklaşımıyla medikal NER modeli. Veri seti temizleme, etiket normalizasyonu, model eğitimi, değerlendirme ve Streamlit tabanlı arayüz adımlarından oluşan uçtan uca bir NLP pipeline geliştirilmiştir.

DeneySEL sonuçlarda klasik model organ/sistem ve tanı aşaması görevlerinde çoğunluk baz çizgisine göre daha anlamlı sonuçlar üretmiştir. Sarkazm, duygu ve konuşma amacı görevlerinde ise sınıf dengesizliği nedeniyle çoğunluk sınıfı metrikleri yüksek görünmüş, modelin az temsil edilen sınıfları ayırt etmede zorlandığı görülmüştür. BERT tabanlı sınıflandırma modeli 0,5243 doğruluk ve 0,3911 F1 değeri elde etmiş; NER modeli ise 0,8879 token doğruluğu ve 0,3100 F1 değeri üretmiştir.

2. Giriş

Medikal diyaloglar, yalnızca hastalık veya semptom adlarını değil, aynı zamanda konuşmacının niyetini, duygusal tonunu, tanısal düşünme sürecini ve klinik karar bağlamını da içerir. Bu nedenle hasta-doktor konuşmalarını anlamlandırmak, klasik metin sınıflandırmadan daha karmaşık bir NLP problemidir. Bir cümlemin “soru”, “talimat”, “hipotez”, “tedavi önerisi” veya “şaka” olması, klinik iletişimde farklı anlamlara gelir.

Bu projenin amacı, Türkçe medikal diyaloglarda her repliğin iletişimsel ve medikal bağlamını otomatik olarak analiz etmektir. Uygulamanın gerçek dünya karşılığı; klinik görüşme özetleme, hasta-doktor iletişimi analizi, medikal eğitim simülasyonları, konuşma kayıtlarından yapılandırılmış bilgi çıkarımı ve karar destek sistemlerine ön işleme sağlama gibi alanlardır. Proje gerçek klinik kullanım için değil, eğitim ve araştırma amaçlı bir NLP prototipi olarak değerlendirilmelidir.

3. Literatür Özeti

Bu proje, Türkçe medikal diyaloglar üzerinde konuşma amacı, duygu, sarkazm, tanı aşaması, organ/sistem sınıflandırması ve medikal varlık tanıma görevlerini ele almaktadır. Bu nedenle literatür; biyomedikal doğal dil işleme, metin sınıflandırma, Transformer tabanlı modeller, adlandırılmış varlık tanıma ve sarkazm tespiti başlıkları altında incelenmiştir.

Houssein vd. [1], biyomedikal doğal dil işleme alanında kullanılan makine öğrenmesi ve derin öğrenme tekniklerini kapsamlı biçimde incelemiştir. Çalışmada elektronik sağlık kayıtları ve klinik anlatı metinleri gibi serbest biçimli tıbbi metinlerde önemli bilgilerin yapılandırılmamış biçimde bulunduğu belirtilmiştir. Bu nedenle NLP tekniklerinin, klinik metinlerden anlamlı ve yapılandırılmış bilgi çıkarımı için önemli olduğu vurgulanmıştır. Bizim projemizde House M.D. medikal diyaloglarından konuşma amacı, duygu, tanı aşaması ve medikal varlık çıkarımı yapılması, bu çalışmada ele alınan biyomedikal NLP yaklaşımıyla benzerlik göstermektedir.

Li vd. [2], derin öğrenme tabanlı adlandırılmış varlık tanıma yöntemlerini inceleyen kapsamlı bir çalışma sunmuştur. Çalışmada NER'in metin içerisindeki önceden tanımlanmış varlık türlerini tespit etmeyi amaçladığı ve soru cevaplama, bilgi çıkarımı, metin özetleme gibi birçok NLP uygulaması için temel bir bileşen olduğu belirtilmiştir. Bu proje kapsamında semptom, test, ilaç ve prosedür gibi medikal varlıkların tespit edilmesi, NER probleminin medikal alandaki bir uygulaması olarak değerlendirilebilir.

Liu vd. [3], tıbbi kayıtlar üzerinde adlandırılmış varlık tanıma için Med-BERT adlı ön eğitilmiş bir model önermiştir. Çalışmada medikal kayıtların kendine özgü terminoloji, uzun varlık yapıları ve bağlama bağlı ifadeler içerdiği belirtilmiş; bu nedenle genel dil modellerinin medikal alan için her zaman yeterli olmayabileceği ifade edilmiştir. Bu sonuç, bizim projemizde BERT tabanlı yaklaşımların kullanılmasını ve ileride Türkçe medikal alana özel ön eğitilmiş modellerle performansın artırılabilceğini desteklemektedir.

Naseem vd. [4], biyomedikal adlandırılmış varlık tanıma için BioALBERT modelini önermiştir. Çalışmada biyomedikal NER'in sınırlı etiketli veri, kısaltmalar, bağlama göre değişebilen varlık türleri ve alan terimlerinin karmaşıklığı nedeniyle zor bir problem olduğu belirtilmiştir. Bu durum, bizim projemizde NER modelinin token doğruluğu yüksek olmasına rağmen F1 değerinin daha düşük kalmasını açıklayan literatürle uyumludur. Medikal varlık sınırlarının doğru belirlenmesi, özellikle kısa ve bağlama bağımlı diyalog cümlelerinde zorlaşmaktadır.

Yang vd. [5], COVID-19 epidemiyolojik araştırma metinleri üzerinde BERT tabanlı bir adlandırılmış varlık tanıma modeli geliştirmiştir. Çalışma, sağlık alanındaki özel metinlerde BERT tabanlı modellerin kişi, yer, kurum ve hastalık ilişkili bilgileri çıkarmada etkili olabileceğini göstermektedir. Bu yaklaşım, bizim projemizde medikal diyaloglarda organ/sistem, semptom ve test gibi varlıkların analiz edilmesiyle yöntemsel olarak benzerlik taşımaktadır.

Genel olarak IEEE literatürü, medikal doğal dil işlemenin yapılandırılmamış metinlerden anlamlı bilgi çıkarımı için önemli olduğunu göstermektedir. Bu çalışmalarda özellikle BERT tabanlı modellerin, NER ve metin sınıflandırma görevlerinde güçlü sonuçlar verdiği görülmektedir. Bununla birlikte medikal metinlerde sınırlı etiketli veri, sınıf dengesizliği, bağlama bağlı ifadeler ve alan terimlerinin karmaşıklığı hâlâ temel zorluklar arasındadır. Bu proje de benzer şekilde, Türkçe medikal diyaloglarda klasik makine öğrenmesi ve BERT tabanlı yöntemleri kullanarak çok görevli bir NLP analizi gerçekleştirmiştir.

4. Kullanılan Yöntemler

Veri seti, House M.D. dizisindeki medikal diyaloglardan oluşturulmuş ve model eğitime uygun hale getirilmek üzere ön işleme adımlarından geçirilmiştir. Temizleme aşamasında boş metinler çıkarılmış, etiketler küçük harfe dönüştürülmüş, “unknown” sınıfları ayrılmış ve tanı aşaması, duygu ve sarkazm etiketleri normalize edilmiştir. Ayrıca medical_entities alanı JSON olarak okunarak medikal varlık sayısı ve varlık tipi bilgileri çıkarılmıştır.

Klasik makine öğrenmesi tarafında her görev için ayrı model eğitilmiştir. Metinler Türkçe karakterleri destekleyen tokenizer ile ayrılmış, stopword temizliği uygulanmış ve TfidfVectorizer ile sayısal vektörlere dönüştürülmüştür. Konuşmacı bilgisi One-Hot Encoding ile, has_symptom, has_test, has_drug, has_procedure ve alanları ise sayısal özellik olarak eklenmiştir. Sınıflandırıcı olarak Logistic Regression kullanılmıştır.

Derin öğrenme tarafında dbmdz/bert-base-turkish-cased modeli ile metin sınıflandırma yapılmıştır. BERT modeli, metni 128 token sınırıyla tokenize etmiş ve sınıflandırma başlığı üzerinden fine-tune edilmiştir. NER görevinde ise metindeki medikal varlıklar BIO formatına dönüştürülmüş, BERT tabanlı token classification modeliyle semptom, hastalık, ilaç, test ve prosedür benzeri varlıklar tahmin edilmiştir.

5. Deneysel Sonular


Kullanılan temiz veri seti 7281 satırdan ve 28 kolondan oluşmaktadır. En yoğun etiketler konuşma amacı için “açıklama”, duygu için “nötr”, sarkazm için “not_sarcastic”, tanı aşaması için “değerlendirme” ve organ/sistem için “beyin” olmuştur. Bu dağılım, veri setinde belirgin sınıf dengesizliği bulunduğunu göstermektedir.

Tablo 1. Klasik model sonuçları


Görev	Satır	Sınıf	Accuracy	F1
Konuşma amacı	6622	34	0,1811	0,1677
Duygu	6687	28	0,2055	0,2257
Sarkazm	7278	2	0,8537	0,8858
Tanı aşaması	6387	29	0,3052	0,3205
Organ/sistem	3390	31	0,3555	0,3943

Tablo 2. Derin öğrenme sonuçları


Model	Satır	Sınıf	Accuracy	F1
BERT sınıflandırma	7081	186	0,5243	0,3911
BERT tabanlı NER	6558	51	0,8879	0,3100




Şekil 1. Konuşma amacı sınıflandırması karışıklık matrisi




Şekil 2. Duygu sınıflandırması karışıklık matrisi




Şekil 3. Sarkazm sınıflandırması karışıklık matrisi




Şekil 4. Tanı aşaması sınıflandırması karışıklık matrisi




Şekil 5. Organ/sistem sınıflandırması karışıklık matrisi




Şekil 6. Konuşma amacı görevi için epoch bazlı performans grafiği




Şekil 7. Duygu görevi için epoch bazlı performans grafiği



Şekil 8. Sarkazm görevi için epoch bazlı performans grafiği



Şekil 9. Tanı aşaması görevi için epoch bazlı performans grafiği



Şekil 10. Organ/sistem görevi için epoch bazlı performans grafiği

Karışıklık Matrisleri

Şekil 1, konuşma amacı sınıflandırmasına ait karışıklık matrisini göstermektedir. Bu görev, veri setindeki en fazla sınıf içeren problemlerden biridir. “Açıklama”, “hipotez”, “soru”, “talimat” ve “tedavi” gibi bazı sınıfların anlam bakımından birbirine yakın olması modelin bu etiketleri ayırmasını zorlaştırmıştır. Ayrıca bazı konuşma amacı sınıflarının az sayıda örnek içermesi, modelin düşük frekanslı sınıflarda daha fazla hata yapmasına neden olmuştur.

Şekil 2, duygu sınıflandırmasına ait karışıklık matrisini göstermektedir. Duygu sınıflandırmasında “nötr” sınıfının veri setinde baskın olduğu görülmektedir. Model sık görülen duygu sınıflarında daha kararlı tahminler yaparken, az temsil edilen ve anlam bakımından birbirine yakın duygu etiketlerinde daha fazla hata üretmiştir. Bu sonuç, duygu analizinin yalnızca kelime düzeyinde değil, bağlam ve konuşmacı tonu düzeyinde de değerlendirilmesi gerektiğini göstermektedir.

Şekil 3, sarkazm sınıflandırmasına ait karışıklık matrisini göstermektedir. Sarkazm görevi iki sınıflı olduğu için matris diğer görevlere göre daha sade görünmektedir. Ancak veri setinde “not_sarcastic” sınıfının “sarcastic” sınıfına göre çok daha fazla bulunması, accuracy değerinin tek başına yeterli bir başarı ölçütü olmadığını göstermektedir. Bu nedenle sarkazm görevi değerlendirilirken F1 skoru ve sınıf bazlı hata dağılımı da dikkate alınmalıdır.

Şekil 4, tanı aşaması sınıflandırmasına ait karışıklık matrisini göstermektedir. Bu görevde model “değerlendirme”, “hipotez”, “test”, “tedavi” ve “tanı” gibi klinik süreç adımlarını ayırmaya çalışmıştır. Bazı tanı aşamaları gerçek diyaloglarda benzer bağlamlarda kullanıldığı için model bu sınıfları zaman zaman karıştırmıştır. Buna rağmen tanı aşaması görevi, çoğunluk sınıfı baz çizgisine göre daha anlamlı sonuçlar üretmiştir.

Şekil 5, organ/sistem sınıflandırmasına ait karışıklık matrisini göstermektedir. Bu görevde “beyin”, “kalp”, “akciğer”, “kan”, “karaciğer” ve “böbrek” gibi medikal terimler model için güçlü ipuçları sağlamıştır. Bu nedenle organ/sistem sınıflandırması, metindeki açık medikal kavramlardan daha fazla yararlanabilmiştir. Ancak bazı sistemlerin birden fazla organla ilişkili olması, modelin yakın sınıflar arasında kararsız kalmasına neden olmuştur.

Genel olarak karışıklık matrisleri, modelin sık görülen sınıflarda daha başarılı olduğunu; az örnekli, anlamca yakın veya bağlama bağımlı sınıflarda ise daha fazla hata yaptığını göstermektedir. Bu sonuç, veri setindeki sınıf dengesizliğinin model performansı üzerinde belirgin bir etkisi olduğunu ortaya koymaktadır.

Epoch Grafikleri

Şekil 6, konuşma amacı görevi için epoch bazlı performans grafiğini göstermektedir. Konuşma amacı görevi çok sınıflı ve anlam bakımından karmaşık bir sınıflandırma problemidir. Grafik, modelin eğitim sürecinde belirli bir öğrenme sağladığını; ancak sınıf sayısının fazla olması ve bazı etiketlerin birbirine yakın olması nedeniyle performans artışının sınırlı kaldığını göstermektedir.

Şekil 7, duygu görevi için epoch bazlı performans grafiğini göstermektedir. Duygu sınıflandırması, bağlama ve konuşmacı tonuna bağlı olduğu için zorlu bir görevdir. Grafik, modelin bazı duygu sınıflarını öğrenebildiğini ancak tüm sınıflarda dengeli bir başarı elde edemediğini göstermektedir.

Şekil 8, sarkazm görevi için epoch bazlı performans grafiğini göstermektedir. Sarkazm görevi iki sınıflı olduğu için eğitim süreci diğer bazı görevlere göre daha stabil görünmektedir. Ancak sarkazm çoğu zaman açık kelimelerden değil, bağlamdan ve konuşma tarzından anlaşıldığı için modelin bu görevi tamamen çözmesi zordur.

Şekil 9, tanı aşaması görevi için epoch bazlı performans grafiğini göstermektedir. Grafik, modelin klinik süreçle ilişkili bazı örüntüleri öğrenebildiğini göstermektedir. Özellikle test, tedavi, hipotez ve değerlendirme gibi aşamalar belirli medikal ifadelerle ilişkili olduğundan, model bu görevde daha anlamlı sonuçlar üretebilmiştir.

Şekil 10, organ/sistem görevi için epoch bazlı performans grafiğini göstermektedir. Organ/sistem görevi, metinde geçen medikal terimlerin doğrudan ipucu sağlaması nedeniyle daha öğrenilebilir görevlerden biridir. Grafik, modelin eğitim sürecinde organ ve sistem etiketleriyle ilişkili kelime örüntülerini yakalayabildiğini göstermektedir.

Genel olarak epoch grafikleri, modelin bazı görevlerde erken aşamada belirli bir performans seviyesine ulaştığını, ancak tüm görevlerde sürekli ve yüksek bir iyileşme sağlanamadığını göstermektedir. Bunun temel nedenleri arasında sınıf dengesizliği, az örnekli etiketler ve medikal diyalogların bağlama bağımlı yapısı yer almaktadır. Daha dengeli bir veri seti, daha uzun eğitim süresi, hiperparametre optimizasyonu ve medikal Türkçe alanına özel dil modelleri kullanılarak model performansı artırılabilir.

6. Test ve Doğrulama

Model doğrulaması için veri seti her görevde %80 eğitim ve %20 test olacak şekilde ayrılmıştır. Bölme işlemi stratified olarak yapılmıştır. Böylece etiket dağılımı eğitim ve test kümelerinde benzer tutulmuştur.

Tablo 3. Örnek test senaryoları ve model çıktıları

Görev	Girdi	Beklenen	Elde Edilen	Yorum
Konuşma Amacı	“midede tıkalı arterioller.”	talep	talep	Doğru tahmin
Konuşma Amacı	“o eski öksürük haplarından tekrar alabilir miyim?”	soru	soru	Doğru tahmin
Duygu	“lenfoma da olası nedenlerden biridir.”	nötr	düşünceli	Duygu tonu karışmış
Sarkazm	“sonunda sesimi duyabiliyorlar...”	not_sarcastic	not_sarcastic	Doğru tahmin
Organ Sistem	“ofisini incelemek için izin isteyip, akabinde mr çekebiliriz.”	beyin	beyin	Doğru tahmin
Tanı Aşaması	“gündüz vakti uyuyakalıyor ve uyurgezerlik yapıyor...”	değerlendirme	ilk_değerlendirme	Yakın ama hatalı sınıf

Test ve doğrulama sonuçları, görselleştirme bölümünde elde edilen bulgularla uyumludur. Model, açık örüntü içeren bazı örneklerde doğru tahmin üretirken; duygu ve tanı aşaması gibi bağlama daha bağımlı görevlerde yakın ancak hatalı sınıflara yönelebilmektedir. Özellikle “nötr” ifadenin “düşünceli” olarak tahmin edilmesi veya “değerlendirme” etiketinin “ilk_değerlendirme” olarak sınıflandırılması, modelin anlamsal olarak yakın etiketleri karıştırabildiğini göstermektedir. Bu nedenle sonuçlar değerlendirilirken yalnızca accuracy değerine değil, F1 skoru, sınıf dağılımı ve örnek bazlı hata analizine de dikkat edilmelidir.

7. Sonular ve Yorumlanması

Bu projede Trke medikal diyalogların ok boyutlu olarak analiz edilebileceėi gsterilmiřtir. Sistem, yalnızca metin sınıflandırması yapmakla kalmamıř; konuřmacı, medikal varlık varlıėı ve varlık sayısı gibi ek baėlamsal zellikleri de kullanmıřtır. Bu ynyle proje, klasik NLP zellik mhendisliėi ile Transformer tabanlı derin ėrenme yaklařımını birlikte deėerlendirmiřtir.

Sonular, veri dengesizliėinin model performansını etkilediėini gstermektedir. Organ/sistem ve tanı ařaması grevlerinde model oėunluk baz izgisini geebilmiř; bu da medikal terimlerin ve varlık zelliklerinin bu grevlerde iyi anlamlarını gstermiřtir. Buna karřılık konuřma amacı ve duygu grevlerinde sınıf sayısının fazla olması, bazı etiketlerin birbirine semantik olarak yakın olması ve az rneklı sınıfların bulunması performansı sınırlamıřtır.

NER modelinin token doėruluėu yksek olmasına raėmen F1 deėerinin daha dřk kalması, modelin “O” etiketi dıřındaki gerek medikal varlık sınırlarını yakalamakta zorlandıėını gstermektedir. Bu durum, daha dengeli ve daha ayrıntılı etiketlenmiř bir medikal veri setiyle geliřtirilebilir. Gelecekte veri artırma, etiket birleřtirme, sınıf dengesizliėi iin focal loss veya rnek aėırlıklandırma, daha uzun eėitim ve medikal Trke alanına zel n eėitim uygulanabilir.

8. Kaynaka

- [1] E. H. Houssein, R. E. Mohamed, and A. A. Ali, “Machine Learning Techniques for Biomedical Natural Language Processing: A Comprehensive Review,” *IEEE Access*, vol. 9, pp. 140628-140653, 2021, doi: 10.1109/ACCESS.2021.3119621.
- [2] J. Li, A. Sun, J. Han, and C. Li, “A Survey on Deep Learning for Named Entity Recognition,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 34, no. 1, pp. 50-70, Jan. 2022, doi: 10.1109/TKDE.2020.2981314.
- [3] N. Liu, Q. Hu, H. Xu, X. Xu, and M. Chen, “Med-BERT: A Pretraining Framework for Medical Records Named Entity Recognition,” *IEEE Transactions on Industrial Informatics*, vol. 18, no. 8, pp. 5600-5608, Aug. 2022, doi: 10.1109/TII.2021.3131180.
- [4] U. Naseem, M. Khushi, V. Reddy, S. Rajendran, I. Razzak, and J. Kim, “BioALBERT: A Simple and Effective Pre-trained Language Model for Biomedical Named Entity Recognition,” in *Proc. 2021 International Joint Conference on Neural Networks (IJCNN)*, Shenzhen, China, 2021, pp. 1-7, doi: 10.1109/IJCNN52387.2021.9533884.
- [5] C. Yang, L. Sheng, Z. Wei, and W. Wang, “Chinese Named Entity Recognition of Epidemiological Investigation of Information on COVID-19 Based on BERT,” *IEEE Access*, vol. 10, pp. 104156-104168, 2022, doi: 10.1109/ACCESS.2022.3210119.